

what

• 对于含有等式和不等式的最优化问题,

$$\min f(x)$$

$$\text{s.t. } g_j(x) \leq 0 \quad (j=1, 2, \dots, m)$$

$$h_k(x) = 0 \quad (k=1, 2, \dots, l)$$

KKT条件是判断 x^* 是否为最优解的必要条件, 即:

$$\begin{cases} \frac{\partial f}{\partial x_i} + \sum_{j=1}^m \mu_j \frac{\partial g_j}{\partial x_i} + \sum_{k=1}^l \lambda_k \frac{\partial h_k}{\partial x_i} = 0, \quad (i=1, 2, \dots, n) \\ h_k(x) = 0 \quad (k=1, 2, \dots, l) \\ \mu_j g_j(x) = 0 \quad (j=1, 2, \dots, m) \\ \mu_j \geq 0. \end{cases}$$

等式约束优化问题

参考文献

- 同济7版高数下册 (p.116-118).

what

- $$\min f(x_1, x_2, \dots, x_n)$$

$$\text{s.t. } h_k(x_1, x_2, \dots, x_n) = 0$$

令 $L(x, \lambda) = f(x) + \sum_{k=1}^l \lambda_k h_k(x)$, 函数 $L(x, y)$ 称为 Lagrange 函数, 参数 λ 称为 Lagrange 乘子.

$$\text{联立方程组 } \begin{cases} \frac{\partial L}{\partial x_i} = 0 & (i=1, 2, \dots, n) \\ \frac{\partial L}{\partial \lambda_k} = 0 & (k=1, 2, \dots, l) \end{cases},$$

得到的解为可疑极值点, 由于是必要条件, 具体是否是极值点需根据问题本身的具体情况检验,

不等式约束优化问题

转换

不等式约束问题

↓ 引入松弛变量

等式约束问题

↓ 引入 Lagrang 乘子

无约束优化

具体

$$\min f(x) \quad \text{s.t.} \quad \begin{cases} g_1(x) = a - x \leq 0 \\ g_2(x) = x - b \leq 0 \end{cases} \quad \text{都是 "}\leq\text{" 号}$$

$$\text{对于约束 } g_1 \text{ 与 } g_2 \text{ 加入松弛变量 } a_1^2, b_1^2 \text{ 有 } \begin{cases} h_1(x, a_1) = g_1 + a_1^2 = 0 \\ h_2(x, b_1) = g_2 + b_1^2 = 0 \end{cases}$$

加入 a_1^2, b_1^2 而非 a_1, b_1 是因为 g_1, g_2 这两个不等式的右也必须是同一个已知才能将不等式变为等式。

对于等式约束有

$$L(x, a_1, b_1, \mu_1, \mu_2) = f(x) + \mu_1(a - x + a_1^2) + \mu_2(x - b + b_1^2)$$

$$\begin{cases} \frac{\partial L}{\partial x} = \frac{\partial f(x)}{\partial x} - \mu_1 + \mu_2 = 0 & \frac{\partial L}{\partial \mu_1} = a - x + a_1^2 = 0 \\ \frac{\partial L}{\partial a_1} = 2\mu_1 a_1 = 0 & \frac{\partial L}{\partial b_1} = 2\mu_2 b_1 = 0 & \frac{\partial L}{\partial \mu_2} = x - b + b_1^2 = 0 \end{cases}$$

$$\text{对于 } \mu_1 a_1 = 0 \text{ 有 } \begin{cases} \mu_1 = 0, a_1 \neq 0; \text{ 此时 } g_1 \text{ 不起作用} \\ \mu_1 \geq 0, a_1 = 0, \text{ 此时 } g_1(x) = a - x = 0 \text{ 且 } \mu_1 > 0, \text{ 即 } g_1 \text{ 起作用, 且 } g_1(x) = 0 \end{cases}$$

由此, 方程组可化为

$$\begin{cases} \frac{df}{dx} + \mu_1 \frac{dg_1}{dx} + \mu_2 \frac{dg_2}{dx} = 0, \\ \mu_1 g_1(x) = 0, \quad \mu_2 g_2(x) = 0 \\ \mu_1 \geq 0, \quad \mu_2 \geq 0 \end{cases}$$

为什么KKT的乘子 ≥ 0

由于

$$\frac{\partial f(x^*)}{\partial x_i} + \sum_{j=1}^m \mu_j \frac{\partial g_j(x^*)}{\partial x_i} = 0 \quad (i=1, 2, \dots, n)$$


$$-\frac{\partial f(x^*)}{\partial x_i} = \sum_{j=1}^m \mu_j \frac{\partial g_j(x^*)}{\partial x_i}$$

注意到梯度为向量，上式表示在约束极小值点 x^* 处，函数 $f(x^*)$ 的负梯度一定可以表示


成：即有起作用约束在该点的梯度的线性组合，

为方便作图，假设现在只有两个起作用约束，我们作出图形如下图。注意我们上面推导过，约束起作用时 $g_j(x) = 0$ ，所以此时约束在几何上应该是一簇约束平面。我们假设在 x^* 取得极小值点，若同时满足 $g_1(x) = 0$ 和 $g_2(x) = 0$ ，则 x^k 一定在这两个平面的交线上，且


$$-\nabla f(x^*) = \sum_{j \in J} \mu_j \nabla g_j(x^*), \text{ 即 } -\nabla f(x^k), \nabla g_1(x^k) \text{ 和 } \nabla g_2(x^k) \text{ 共面。}$$



下图是在点 x^k 处沿 $x_1 O x_2$ 面的截面，过点 x^k 作目标函数的负梯度 $-\nabla f(x^k)$ ，它垂直于目标函数的等值线 $f(x) = C$ （高数课本：一点的梯度与等值线相互垂直），且指向目标函数 $f(x)$ 的最速减小方向。再作约束函数 $g_1(x) = 0$ 和 $g_2(x) = 0$ 的梯度 $\nabla g_1(x^k)$ 和 $\nabla g_2(x^k)$ ，它们分别垂直 $g_1(x) = 0$ 和 $g_2(x) = 0$ 两曲面在 x^k 的切平面，并形成一锥形夹角区域。此时，可能有a、b两种情形：




a)



b)

我们先来看情形b：若3个向量的位置关系如b所示，即 $-\nabla f$ 落在 ∇g_1 和 ∇g_2 所形成的锥角区外的一侧。此时，作等值面 $f(\mathbf{x}) = C$ 在点 \mathbf{x}^k 的切平面（它与 $-\nabla f(\mathbf{x}^k)$ 垂直），我们发现：沿着与负梯度 $-\nabla f$ 成锐角的方向移动（如下图红色箭头方向），只要在红色区域取值，目标函数 $f(\mathbf{x})$ 总能减小。而红色区域是可行域（ $f(\mathbf{x}) = C$ ， C 取不同的常数能得到不同的等值线，因此能取到红色区域），因此既可减小目标函数值，又不破坏约束条件。这说明 \mathbf{x}^k 仍可沿约束曲面移动而不破坏约束条件，且目标函数值还能够减小。所以 \mathbf{x}^k 不是稳定的最优解，即不是局部极值点。



b)

反过头来看情形a： $-\nabla f$ 落在 ∇g_1 和 ∇g_2 形成的锥角内。此时，同样作 $f(\mathbf{x}) = C$ 在点 \mathbf{x}^k 与 $-\nabla f$ 垂直的切平面。当从 \mathbf{x}^k 出发沿着与负梯度 $-\nabla f$ 成锐角的方向移动时，虽然能使目标函数值减小，但此时任何一点都不在可行区域内。显然，此时 \mathbf{x}^k 就是局部最优解 \mathbf{x}^* ，再做任何移动都将破坏约束条件，故它是稳定点。

why ≥ 0 ? →

由于 $-\nabla f(\mathbf{x}^*)$ 和 $\nabla g_1(\mathbf{x}^*)$ 、 $\nabla g_2(\mathbf{x}^*)$ 在一个平面内，所以前者可看成是后两者的线性组合。又由上面的几何分析知， $-\nabla f(\mathbf{x}^*)$ 在 $\nabla g_1(\mathbf{x}^*)$ 和 $\nabla g_2(\mathbf{x}^*)$ 的夹角之间，所以线性组合的系数为正，有

$$-\nabla f(\mathbf{x}^*) = \mu_1 \nabla g_1(\mathbf{x}^*) + \mu_2 \nabla g_2(\mathbf{x}^*), \text{ 且 } \mu_1 > 0, \mu_2 > 0.$$

这就是 $\mu_j > 0$ 的原因。类似地，当有多个不等式约束同时起作用时，要求 $-\nabla f(\mathbf{x}^*)$ 处于 $\nabla g_j(\mathbf{x}^*)$ 形成的超角锥（高维图形，我姑且称之为“超”）之内。

3.总结：同时包含等式和不等式约束的一般优化问题

$$\begin{aligned} \min f(\mathbf{x}) \\ s. t. g_j(\mathbf{x}) \leq 0 (j = 1, 2, \dots, m) \\ h_k(\mathbf{x}) = 0 (k = 1, 2, \dots, l) \end{aligned}$$

KKT条件（ \mathbf{x}^* 是最优解的必要条件）为

$$\begin{cases} \frac{\partial f}{\partial x_i} + \sum_{j=1}^m \mu_j \frac{\partial g_j}{\partial x_i} + \sum_{k=1}^l \lambda_k \frac{\partial h_k}{\partial x_i} = 0, (i = 1, 2, \dots, n) \\ h_k(\mathbf{x}) = 0, (k = 1, 2, \dots, l) \\ \mu_j g_j(\mathbf{x}) = 0, (j = 1, 2, \dots, m) \\ \mu_j \geq 0. \end{cases}$$

注意，对于等式约束的Lagrange乘子，并没有非负的要求！以后求其极值点，不必再引入松弛变量，直接使用KKT条件判断！

这样，我们就推导完了KKT条件。各位看官可以自己分别罗列并比较一下：无约束优化、等式约束优化和等式+不等式约束优化条件下某点为局部最优解（极值点）的必要条件。