

The background of the slide features a blue gradient. On the left side, there are several lines of binary code (0s and 1s) in a light blue, slightly blurred font. On the right side, there is a faint, white wireframe globe. The title text is positioned in the lower right area of the slide.

§ 9. Markov矩阵和正矩阵

一 问题引入

设某小镇有3000人，选用两种牙膏A-1和A-2，本年度有1000人选用牙膏A-1，2000人选用牙膏A-2。据调查，下一年度选用牙膏A-1的居民，60%将继续选用A-1，40%将改选A-2。选用牙膏A-2的居民，70%将继续选用A-2，30%将改选A-1。可以总结如下表

	明年选用A-1的居民	明年选用A-2的居民
今年选用A-1的居民	60%	40%
今年选用A-2的居民	30%	70%

一 问题引入

设下一年度选用A-1为 x_1 人, 选用A-2为 y_1 人.

(本年度选用A-1为 $x_0 = 1000$ 人, 选用A-2为 $y_0 = 2000$ 人). 我们有

$$\begin{pmatrix} x_1 \\ y_1 \end{pmatrix} = \begin{pmatrix} 0.6 & 0.3 \\ 0.4 & 0.7 \end{pmatrix} \begin{pmatrix} x_0 \\ y_0 \end{pmatrix}$$

$\begin{pmatrix} 0.6 & 0.3 \\ 0.4 & 0.7 \end{pmatrix}$ 被称为转移(概率)矩阵(transition matrix). 假设这个规律不变,

后年度选用A-1为 x_2 人, 选用A-2为 y_2 人, 则有 $\begin{pmatrix} x_2 \\ y_2 \end{pmatrix} = \begin{pmatrix} 0.6 & 0.3 \\ 0.4 & 0.7 \end{pmatrix} \begin{pmatrix} x_1 \\ y_1 \end{pmatrix}$

$$\begin{pmatrix} x_2 \\ y_2 \end{pmatrix} = \begin{pmatrix} 0.6 & 0.3 \\ 0.4 & 0.7 \end{pmatrix}^2 \begin{pmatrix} x_0 \\ y_0 \end{pmatrix}$$

一 问题引入

一般地, 在上述规律不变的情况下, 我们得到了向量序列

$$\begin{pmatrix} x_0 \\ y_0 \end{pmatrix}, \quad \begin{pmatrix} x_1 \\ y_1 \end{pmatrix}, \quad \begin{pmatrix} x_2 \\ y_2 \end{pmatrix}, \quad \dots, \begin{pmatrix} x_k \\ y_k \end{pmatrix}, \dots$$

$$\begin{pmatrix} x_k \\ y_k \end{pmatrix} = \begin{pmatrix} 0.6 & 0.3 \\ 0.4 & 0.7 \end{pmatrix}^k \begin{pmatrix} x_0 \\ y_0 \end{pmatrix}$$

其中, x_k 是第 k 年度选用 A-1 的人数, y_k 是第 k 年度选用 A-2 的人数. (今年是第 0 年度)

这个序列给出一个马尔科夫链(Markov chain), 可以预测随时间变化序列未来的趋势。

$\begin{pmatrix} 0.6 & 0.3 \\ 0.4 & 0.7 \end{pmatrix}$ 是一个 Markov 矩阵, 当 $k \rightarrow +\infty$, $\begin{pmatrix} 0.6 & 0.3 \\ 0.4 & 0.7 \end{pmatrix}^k$ 的极限状态给出了未来的趋势.

一 问题引入

参考文献： 百度文库>专业资料>自然科学>数学 >马尔科夫链，网址：

<http://wenku.baidu.com/link?url=V2b5jZHvANQSeo0zXXSMKd29fEuKLT8-rPkleyC0yzWHp9qRU9ReX1pAolBWeAeCIRUtKdsw55HEFgxqLYI9yJJbN8tCr8c0E5KFkYlBga>

二 Markov矩阵

一个 $n \times n$ 的实矩阵 \mathbf{A} 被称为Markov矩阵，如果它的元素均为非负，且每个列向量分量之和等于1. 例如：

$$\begin{pmatrix} 0.6 & 0.3 \\ 0.4 & 0.7 \end{pmatrix}, \begin{pmatrix} 1 & 1 \\ 0 & 0 \end{pmatrix}, \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \text{ 等.}$$

Markov矩阵也被称为随机矩阵(Stochastic matrix). 一个向量满足分量非负，分量之和等于1 称为随机向量.

二 Markov矩阵

我们使用如下技巧： 设 $\mathbf{A}=(a_{ij})$, 若 $a_{ij} > 0, \forall i, j$, 则写 $\mathbf{A} > 0$.

设 α 和 β 是两个实向量, $\alpha \geq \beta$ 意味着 α 的每个分量均大于等于 β 的相应分量, 例如:

$$\begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} \geq \begin{pmatrix} 1 \\ 1 \\ 3 \end{pmatrix}.$$

我们写 $\alpha > \beta$ 若 α 的每个分量严格大于 β 的相应分量.

性质: 设 $\mathbf{A} > 0, \alpha \geq \beta$ 且 $\alpha \neq \beta, \exists \varepsilon > 0, \mathbf{A}\alpha > (1 + \varepsilon)\mathbf{A}\beta$.

二 Markov矩阵

由定义，Markov矩阵的列向量是随机向量.

基本性质：

(1) 设 \mathbf{A} 是 n 阶Markov矩阵， \mathbf{p} 是 n 维随机向量，则 \mathbf{Ap} 是一个 n 维随机向量.

证明： 设 $\mathbf{A} = (\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n)$, \mathbf{v}_i 是 \mathbf{A} 的第 i 列

$$\mathbf{p} = \begin{pmatrix} p_1 \\ \vdots \\ p_n \end{pmatrix}, p_1 + \dots + p_n = 1, p_i \geq 0.$$

$$\mathbf{Ap} = p_1 \mathbf{v}_1 + \dots + p_n \mathbf{v}_n.$$

$$(1, 1, \dots, 1)\mathbf{A} = (1, 1, \dots, 1), (1, 1, \dots, 1)\mathbf{p} = 1$$

$$\Rightarrow (1, 1, \dots, 1)\mathbf{Ap} = 1.$$

二 Markov矩阵

(2) 一个Markov矩阵 \mathbf{A} 总有特征值1, 其余特征值长度小于等于1.

证明: 因为 $|\lambda\mathbf{I} - \mathbf{A}| = |\lambda\mathbf{I} - \mathbf{A}^T|$, 且 \mathbf{A} 和 \mathbf{A}^T 有相同的特征值. 由定义

$(1, 1, \dots, 1)\mathbf{A} = (1, 1, \dots, 1)$, 即 $\mathbf{A}^T \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}$. 所以 \mathbf{A}^T 有特征值1, $\begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}$ 是特征向量.

假设 \mathbf{A} 存在特征值 $\lambda_0 \in \mathbb{C}$, $|\lambda_0| > 1$, $\mathbf{A}\alpha = \lambda_0\alpha$.

设 $\alpha = \begin{pmatrix} z_1 \\ \vdots \\ z_n \end{pmatrix}$, $z_i \in \mathbb{C}$, $\mathbf{A} = (a_{ij})_{n \times n}$ 令 $\alpha^+ = \begin{pmatrix} |z_1| \\ \vdots \\ |z_n| \end{pmatrix}$, $\mathbf{A}\alpha^+ = \beta = \begin{pmatrix} \omega_1 \\ \vdots \\ \omega_n \end{pmatrix}$, $\omega_i \in \mathbb{R}$, $\omega_i \geq 0$.

二 Markov矩阵

$$\omega_i = (a_{i1}, \dots, a_{in}) \begin{pmatrix} |z_1| \\ \vdots \\ |z_n| \end{pmatrix} = a_{i1}|z_1| + \dots + a_{in}|z_n| \geq |a_{i1}z_1 + \dots + a_{in}z_n| = |\lambda_0 z_i| = |\lambda_0| |z_i|$$

因此, $\mathbf{A}\alpha^+ \geq |\lambda_0|\alpha^+$.

因为 \mathbf{A} 非负, $\mathbf{A}(\mathbf{A}\alpha^+) \geq \mathbf{A}(|\lambda_0|\alpha^+) = |\lambda_0|\mathbf{A}\alpha^+ \geq |\lambda_0|^2\alpha^+$

$\Rightarrow \mathbf{A}^k\alpha^+ \geq |\lambda_0|^k\alpha^+$. 因为 $(1, \dots, 1)\mathbf{A} = (1, \dots, 1)$, 不等式两端均从左边乘上 $(1, \dots, 1)$ 则有,

$$(1, \dots, 1)\mathbf{A}^k\alpha^+ = (1, 1, \dots, 1)\alpha^+ = |z_1| + \dots + |z_n|.$$

$$(1, \dots, 1)\lambda_0^k\alpha^+ = |\lambda_0|^k(|z_1| + \dots + |z_n|).$$

因此 $|\lambda_0| \leq 1$.

二 Markov矩阵

由此性质:存在关于 $\lambda = 1$ 特征向量 α_0 , $\mathbf{A}\alpha_0 = \alpha_0$.

性质(2) 中“其余特征值的长度满足 $|\lambda| \leq 1$ 的等号不能去掉”.

例如:

$\mathbf{P} = \begin{pmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix}$ 是一个置换阵, 它的特征值是 $\lambda_1 = 1, \lambda_2 = e^{i\frac{2\pi}{3}}, \lambda_3 = e^{i\frac{4\pi}{3}}$

$|\lambda_1| = |\lambda_2| = |\lambda_3|$. 可以看到, $\mathbf{P}^3 = \mathbf{I}_3$, 因此当 $k \rightarrow +\infty$, \mathbf{P}^k 无极限.

我们考虑一类特殊的Markov矩阵, 使得极限存在.

三 正Markov矩阵

定义：一个正Markov矩阵是一个Markov矩阵，其元素均大于0.

例如： $\begin{pmatrix} 0.7 & 0.2 \\ 0.3 & 0.8 \end{pmatrix}$ 是正Markov矩阵， $\begin{pmatrix} 1 & 1 \\ 0 & 0 \end{pmatrix}$ 不是正Markov矩阵.

我们来看二阶正Markov矩阵，即 $\mathbf{P} = \begin{pmatrix} 1-a & b \\ a & 1-b \end{pmatrix}$. $0 < a < 1, 0 < b < 1$. 使用归纳法得到

$$\mathbf{P}^n = \frac{1}{a+b} \begin{pmatrix} b & b \\ a & a \end{pmatrix} + \frac{(1-a-b)^n}{a+b} \begin{pmatrix} a & -b \\ -a & b \end{pmatrix}, \quad 0 < a < 1, 0 < b < 1, \Rightarrow |1-a-b| < 1 \Rightarrow (1-a-b)^n \rightarrow 0, n \rightarrow +\infty.$$

因此, $\lim_{n \rightarrow \infty} \mathbf{P}^n = \begin{pmatrix} \frac{b}{a+b} & \frac{b}{a+b} \\ \frac{a}{a+b} & \frac{a}{a+b} \end{pmatrix}$ 这个极限矩阵的列向量是特征向量，满足分量均大于0，分量之和等于1(随机向量).

这个极限矩阵的列向量是特征向量，满足分量均大于0，分量之和等于1(随机向量).

四 正矩阵

$$\mathbf{P} \begin{pmatrix} \frac{b}{a+b} \\ \frac{a}{a+b} \end{pmatrix} = \begin{pmatrix} \frac{b}{a+b} \\ \frac{a}{a+b} \end{pmatrix}.$$

$\lambda = 1$ 是一个特征值, 另一个特征值是 $[(1-a) + (1-b)] - 1 = 1 - a - b$.

$1 - a - b \neq 1 \Rightarrow \lambda = 1$ 的代数重数=几何重数=1.

若 a 或 b 等于 0, 1, \mathbf{P} 不再是正 Markov 矩阵, 以上讨论不一定成立. 例如 $a = b = 0$, $\lambda = 1$ 是 2 重特征值.

$a = 1, b = 1$, $\mathbf{P} = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$, $\mathbf{P}^2 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$, $\mathbf{P}^3 = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$, 即 $\lim_{m \rightarrow \infty} \mathbf{P}^n$ 不存在.

三 正Markov矩阵

定理：设 \mathbf{A} 是正Markov阵，则 $\lambda = 1$ 是唯一的长度为1的特征值，且 $\lambda = 1$ 代数重数和几何重数均为1，存在唯一随机向量 α_0 使得 $\mathbf{A}\alpha_0 = \alpha_0$, α_0 称为稳定状态向量.
这个定理是**Perron – Frobenius**定理的特殊情形.

例如：

$$\mathbf{A} = \begin{pmatrix} 0.80 & 0.05 \\ 0.2 & 0.95 \end{pmatrix}, \alpha_0 = \begin{pmatrix} 0.2 \\ 0.8 \end{pmatrix}, \mathbf{A}\alpha_0 = \alpha_0.$$

定理：设 \mathbf{A} 是一个 n 阶正Markov阵， α_0 是稳定状态向量，则

$$\lim_{m \rightarrow \infty} \mathbf{A}^m = (\alpha_0, \dots, \alpha_0)_{n \times n}$$

三 正Markov矩阵

证明：存在可逆矩阵 \mathbf{P} , $\mathbf{P}^{-1}\mathbf{A}\mathbf{P} = \mathbf{J} = \begin{pmatrix} \mathbf{J}_1 & & \\ & \ddots & \\ & & \mathbf{J}_s \end{pmatrix}$, \mathbf{J}_i 是若当块(Jordan block).

$\mathbf{J}_i = \begin{pmatrix} \lambda_i & 1 & & \\ & \ddots & \ddots & \\ & & \ddots & 1 \\ & & & \lambda_i \end{pmatrix}$ 对于特征值 $\lambda = 1$, 只有一个一阶若当块, 不妨记为 $\mathbf{J}_1 = (1)$, 则 $\mathbf{P}^{-1}\mathbf{A}\mathbf{P} =$

$$\begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & \mathbf{J}_2 & & \\ \vdots & & \ddots & \\ 0 & & & \mathbf{J}_s \end{pmatrix} \quad (\mathbf{P}^{-1}\mathbf{A}\mathbf{P})^m = \mathbf{P}^{-1}\mathbf{A}^m\mathbf{P} = \begin{pmatrix} \mathbf{J}_1^m & & \\ & \ddots & \\ & & \mathbf{J}_s^m \end{pmatrix}, \quad \mathbf{J}_i^m = \begin{pmatrix} \lambda_i^m & & \\ & \ddots & \\ & & \lambda_i^m \end{pmatrix}_{\mathbf{n}_i \times \mathbf{n}_i} \quad i \geq 2$$

三 正Markov矩阵

因为 $|\lambda_i| < 1, i \geq 2$, 当 $m \rightarrow +\infty, \lambda_i^m \rightarrow 0$. 若 $n_i = 1$, 则 $\lim_{m \rightarrow \infty} \mathbf{J}_i^m = \mathbf{0}$.

若 $n_i > 1, \mathbf{J}_i = \lambda_i \mathbf{I} + \mathbf{J}_0, \mathbf{J}_0 = \begin{pmatrix} 0 & 1 & & \\ & \ddots & \ddots & \\ & & \ddots & 1 \\ & & & 0 \end{pmatrix}_{n_i \times n_i}, \mathbf{J}_0^{n_i} = \mathbf{0}$. 当 $m \rightarrow +\infty, \lim_{m \rightarrow \infty} \mathbf{J}_i^m = \mathbf{0}$.

$$\Rightarrow \lim_{m \rightarrow \infty} (\mathbf{P}^{-1} \mathbf{A} \mathbf{P})^m = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & & & \\ \vdots & \mathbf{0} & & \\ 0 & & & \end{pmatrix} = \begin{pmatrix} 1 \\ \vdots \\ 0 \end{pmatrix} \begin{pmatrix} 1 & \cdots & 0 \end{pmatrix} = \mathbf{B}$$

三 正Markov矩阵

$\Rightarrow \lim_{m \rightarrow \infty} \mathbf{A}^m = \mathbf{PBP}^{-1} = \mathbf{C}$ 极限是秩等于1的矩阵.

\mathbf{A} 是正Markov矩阵, 则 \mathbf{A}^m 也是正Markov矩阵.

$$(1, \dots, 1)\mathbf{A} = (1, \dots, 1) \quad (1, \dots, 1)\mathbf{A}^m = (1, \dots, 1).$$

即 $\lim_{m \rightarrow \infty} \mathbf{A}^m$ 是一个Markov阵.

设 $\mathbf{C} = (t_1\alpha, \dots, t_n\alpha)$ (注 $\text{rank } \mathbf{C} = 1$)

$$\mathbf{A}\mathbf{A}^m = \mathbf{A}^{m+1} \Rightarrow \mathbf{A} \lim_{m \rightarrow \infty} \mathbf{A}^m = \lim_{m \rightarrow \infty} \mathbf{A}^{m+1} \Rightarrow \mathbf{A}\mathbf{C} = \mathbf{C}.$$

即 \mathbf{C} 的每一列是 \mathbf{A} 关于特征值为1的特征值,

且 \mathbf{C} 的每一列均为随机向量, 因此 $t_1 = t_2 = \dots = t_n = 1, \alpha = \alpha_0$

三 正Markov矩阵

例如:

$$\mathbf{A} = \begin{pmatrix} \frac{1}{2} & \frac{1}{6} & \frac{1}{3} \\ \frac{1}{4} & \frac{1}{6} & \frac{1}{3} \\ \frac{1}{4} & \frac{2}{3} & \frac{1}{3} \end{pmatrix} \quad \mathbf{A} = \begin{pmatrix} \frac{8}{9} \\ \frac{2}{3} \\ 1 \end{pmatrix} = \begin{pmatrix} \frac{8}{9} \\ \frac{2}{3} \\ 1 \end{pmatrix} \quad N(\mathbf{A} - \mathbf{I}_3) = \left\{ c \begin{pmatrix} \frac{8}{23} \\ \frac{6}{23} \\ \frac{9}{23} \end{pmatrix} \mid c \in \mathbb{R} \right\} \Rightarrow \alpha_0 = \frac{1}{23} \begin{pmatrix} 8 \\ 6 \\ 9 \end{pmatrix} \Rightarrow$$
$$\lim_{m \rightarrow \infty} \mathbf{A}^m = \frac{1}{23} \begin{pmatrix} 8 & 8 & 8 \\ 6 & 6 & 6 \\ 9 & 9 & 9 \end{pmatrix}.$$

三 正Markov矩阵

例如, 对于城市和郊区的人口流动模型, $\begin{pmatrix} u_i \\ v_i \end{pmatrix}$ 表示第*i*年 城市和农村的人口.

人口流动规律为: 每年80%的城市人口不动, 20%的城市人口流动到郊区; 每年95%的郊区人口不动, 5% 的郊区人口流动到城市, 则

$$\begin{aligned} u_{i+1} &= 0.8u_i + 0.05v_i \\ v_{i+1} &= 0.2u_i + 0.95v_i \end{aligned} \quad \text{即} \quad \begin{pmatrix} u_{i+1} \\ v_{i+1} \end{pmatrix} = \begin{pmatrix} 0.8 & 0.05 \\ 0.2 & 0.95 \end{pmatrix} \begin{pmatrix} u_i \\ v_i \end{pmatrix}$$

$$\text{令 } \mathbf{A} = \begin{pmatrix} 0.8 & 0.05 \\ 0.2 & 0.95 \end{pmatrix}, \text{ 则 } \mathbf{A} \begin{pmatrix} 0.2 \\ 0.8 \end{pmatrix} = \begin{pmatrix} 0.2 \\ 0.8 \end{pmatrix}, \quad \mathbf{A} \begin{pmatrix} -1 \\ 1 \end{pmatrix} = 0.75 \begin{pmatrix} -1 \\ 1 \end{pmatrix}.$$

三 正Markov矩阵

设城市和郊区的总人口为 S , 且 $u_1 = 0.9S, v_1 = 0.1S$. 设 $\begin{pmatrix} u_1 \\ v_1 \end{pmatrix} = [a \begin{pmatrix} 0.2 \\ 0.8 \end{pmatrix} + b \begin{pmatrix} -1 \\ 1 \end{pmatrix}]S$

$$\begin{pmatrix} u_2 \\ v_2 \end{pmatrix} = \mathbf{A} \begin{pmatrix} u_1 \\ v_1 \end{pmatrix} = a \begin{pmatrix} 0.2 \\ 0.8 \end{pmatrix} + 0.75b \begin{pmatrix} -1 \\ 1 \end{pmatrix} \Rightarrow \mathbf{f}_k = \mathbf{A}^{k+1} \begin{pmatrix} u_1 \\ v_1 \end{pmatrix} = [a \begin{pmatrix} 0.2 \\ 0.8 \end{pmatrix} + 0.75^k b \begin{pmatrix} -1 \\ 1 \end{pmatrix}]S.$$
$$\Rightarrow \mathbf{f}_k \rightarrow a \begin{pmatrix} 0.2 \\ 0.8 \end{pmatrix} S = \begin{pmatrix} 0.2 \\ 0.8 \end{pmatrix} S.$$

三 正Markov矩阵

一般地, 设 \mathbf{A} 是一个正Markov矩阵, 设 $\lambda_1 = 1$ 对应的特征向量(各分量之和为1) \mathbf{x}_1 称为稳定状态(Steady state). 设 $\mathbf{f}_1 = a_1 \mathbf{x}_1 + \dots + a_n \mathbf{x}_n$, 设 $\mathbf{f}_{k+1} = \mathbf{A}^k \mathbf{f}_1$, 则 $\lim_{k \rightarrow \infty} \mathbf{f}_{k+1} = a_1 \mathbf{x}_1$.

若 \mathbf{f}_1 满足各分量之和为1, 则 \mathbf{f}_k 也满足这个性质. 显然, $a_1 \mathbf{x}_1$ 也满足分量之和为1 $\Rightarrow a_1 = 1$. 即 $\mathbf{f}_\infty = \mathbf{x}_1$.

注: 若 \mathbf{A} 是非正Markov矩阵, 则可能存在不止一个特征值的模长为1, 从而可能没有稳定状态. 例如:

$\mathbf{A} = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$, 有 $\lambda_1 = 1, \lambda_2 = -1$. Markov矩阵特征值的性质能部分地推广到非负矩阵. 我们考虑正矩阵的情形.

四正矩阵

设 $\mathbf{A} = (\mathbf{a}_{ij})_{n \times n}$, 若 $a_{ij} > 0, \forall i, j = 1, \dots, n$, 则称 \mathbf{A} 为正矩阵. 正Markov矩阵是正矩阵的特殊情形.

定义: 一个方阵 \mathbf{A} 的谱半径(记作 $\rho(\mathbf{A})$)是 \mathbf{A} 的特征值长度的最大值. 例如: $\mathbf{A} = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix}$, $\rho(\mathbf{A}) = 1$.

四正矩阵

Perron-Frobenius定理： 设 $\mathbf{A} = (a_{ij})_{n \times n}$ 是一个正矩阵，则

- (a) $\rho(\mathbf{A})$ 是 \mathbf{A} 的一个特征值，它有正特征向量；
- (b) $\rho(\mathbf{A})$ 是 \mathbf{A} 的长度等于 $\rho(\mathbf{A})$ 的唯一特征值；
- (c) $\rho(\mathbf{A})$ 的几何重数等于1；
- (d) $\rho(\mathbf{A})$ 的代数重数等于1。

四正矩阵

证明:

(a) 设 λ 是 \mathbf{A} 的一个特征值, $|\lambda| = \rho(\mathbf{A})$.

设 $\alpha = \begin{pmatrix} z_1 \\ \vdots \\ z_n \end{pmatrix}$, $z_i \in \mathbb{C}$, $\alpha \neq 0$, $\mathbf{A}\alpha = \lambda\alpha$. 考虑 $\alpha^+ = \begin{pmatrix} |z_1| \\ \vdots \\ |z_n| \end{pmatrix}$,

检查 $\mathbf{A}\alpha^+ \geq \rho(\mathbf{A})\alpha^+$, 若 $\mathbf{A}\alpha^+ \neq \rho(\mathbf{A})\alpha^+$.

因为 \mathbf{A} 是正矩阵, $\mathbf{A}(\mathbf{A}\alpha^+) \geq \rho(\mathbf{A})\alpha^+$, 即 $\exists \varepsilon > 0$, $\mathbf{A}^2\alpha^+ > (1 + \varepsilon)\rho(\mathbf{A})^2\alpha^+$.

$\mathbf{B} = \frac{1}{\rho(\mathbf{A})^2} \mathbf{A}^2$, 则 $\rho(\mathbf{B}) = 1$, $\mathbf{B}\alpha^+ > (1 + \varepsilon)\alpha^+$, $\mathbf{B}^k\alpha^+ > (1 + \varepsilon)^k\alpha^+$, 即 $(\frac{\mathbf{B}}{1 + \varepsilon})^k\alpha^+ > \alpha^+$.
但 $\rho(\frac{\mathbf{B}}{1 + \varepsilon}) < 1 \Rightarrow (\frac{\mathbf{B}}{1 + \varepsilon})^k \rightarrow 0$, 矛盾. 因此 $\mathbf{A}\alpha^+ = \rho(\mathbf{A})\alpha^+$.

四正矩阵

(b) 在 (a) 中我们得到, 若 $\mathbf{A}\alpha = \lambda\alpha, |\lambda| = \rho(\mathbf{A})$, 则 $\mathbf{A}\alpha^+ = \rho(\mathbf{A})\alpha^+$.

这说明 $\sum_{j=1}^n a_{ij}|z_{ij}| = |\sum_{j=1}^n a_{ij}z_j|, i = 1, \dots, n$, 则存在 $c \neq 0 \in \mathbb{C}$, 使得 $c\alpha$ 是一个非负向量.

我们以 $n = 2$ 来解释:

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}, \alpha = \begin{pmatrix} z_1 \\ z_2 \end{pmatrix}, \mathbf{A} \begin{pmatrix} |z_1| \\ |z_2| \end{pmatrix} = \rho(\mathbf{A}) \begin{pmatrix} |z_1| \\ |z_2| \end{pmatrix}. \text{ 由 } \mathbf{A}\alpha = \lambda\alpha,$$

$$\begin{cases} \rho(\mathbf{A})|z_1| = |a_{11}z_1 + a_{12}z_2| \\ \rho(\mathbf{A})|z_2| = |a_{21}z_1 + a_{22}z_2| \end{cases} \Rightarrow \begin{cases} |a_{11}z_1 + a_{12}z_2| = a_{11}|z_1| + a_{12}|z_2| \\ |a_{21}z_1 + a_{22}z_2| = a_{21}|z_1| + a_{22}|z_2| \end{cases}$$

$$\Rightarrow |a_{11}z_1 + a_{12}z_2|^2 = (a_{11}z_1 + a_{12}z_2)(a_{11}\bar{z}_1 + a_{12}\bar{z}_2).$$

$$(a_{11}|z_1| + a_{12}|z_2|)^2 = a_{11}^2|z_1|^2 + 2a_{11}a_{12}|z_1||z_2| + a_{12}^2|z_2|^2.$$

比较上述两个式子右边得:

$$a_{11}a_{12}(z_1\bar{z}_2 + \bar{z}_1z_2) = 2a_{11}a_{12}|z_1||z_2|.$$

四正矩阵

即 $2|z_1||z_2| = (z_1\bar{z}_2 + \bar{z}_1z_2) = 2\operatorname{Re}(z_1\bar{z}_2)$. $|z_1z_2|^2 = z_1z_2\bar{z}_1\bar{z}_2 = (z_1\bar{z}_2)(\bar{z}_1z_2) = ||z_1\bar{z}_2||^2$.

即 $||z_1\bar{z}_2|| = \operatorname{Re}(z_1\bar{z}_2)$, 取 $c = \bar{z}_2$, $c\alpha = \begin{pmatrix} z_1\bar{z}_2 \\ z_2\bar{z}_2 \end{pmatrix} \geq 0$.

我们得到 $\mathbf{A}\alpha = \lambda\alpha$, $|\lambda| = \rho(\mathbf{A})$, 且 $\exists c \in \mathbb{C}$, $c\alpha \geq 0$.

$\mathbf{A}(c\alpha) = \lambda c\alpha \geq 0 \Rightarrow \lambda > 0$, 即 $\lambda = \rho(\mathbf{A})$.

四正矩阵


证明:

(c)由(a)存在 $\alpha > 0$, $\mathbf{A}\alpha > \mathbf{0} = \rho(\mathbf{A})\alpha$, 设存在 $\beta \neq 0$, $\mathbf{A}\beta = \rho(\mathbf{A})\beta$, 可以假设 β 是实向量.

$\exists c > 0$, $\alpha - c\beta \geq 0$, 且存在某一分量为0, 因此 $\alpha - c\beta$ 不严格大于0.

我们接下来介绍如何找 c , 例如 $n = 2$, $\alpha = \begin{pmatrix} a_1 \\ a_2 \end{pmatrix}$, $a_i > 0$, $\beta = \begin{pmatrix} b_1 \\ b_2 \end{pmatrix}$, $b_i > 0$.

考虑函数 $d = a_1 - b_1c$ 和 $d = a_2 - b_2c$, 当 $c = c_0$ 时, $a_1 - b_1c_0 = 0$, $a_2 - b_2c_0 > 0$, 如下图所示.



此时, $\mathbf{A}(\alpha - c\beta) = \rho(\mathbf{A})(\alpha - c\beta)$, 若 $\alpha - c\beta \neq 0$, 左边是一个正向量, 右边有零分量, 矛盾. 因此 $\alpha - c\beta = 0$.

四 正矩阵

证明:

(d) 因为 \mathbf{A} 和 \mathbf{A}^T 有相同特征值. 关于 \mathbf{A}^T , 存在一正向量 $\beta > 0$, $\mathbf{A}^T \beta = \rho(\mathbf{A})\beta$. 考虑 $\beta^\perp = \{x \in \mathbb{R}^n, \beta^T x = 0\}$, 它是 $n-1$ 维的. 任取一组基 $\alpha_2, \dots, \alpha_n$, $\mathbf{A}\alpha = \rho(\mathbf{A})\alpha$, $\alpha > 0$, $\beta^\perp \alpha > 0 \Rightarrow \alpha \notin \beta^\perp$.

令 $\alpha_1 = \alpha$, $\mathbf{P} = (\alpha_1, \dots, \alpha_n)$ 可逆, $\mathbf{A}\alpha_i \in \beta^\perp, i \geq 2$

$$\mathbf{A}(\alpha_1, \dots, \alpha_n) = (\alpha_1, \dots, \alpha_n) \begin{pmatrix} \rho(\mathbf{A}) & 0 \\ 0 & \mathbf{A}_1 \end{pmatrix}.$$

\mathbf{A}_1 不包含属于 $\rho(\mathbf{A})$ 的特征向量, 否则 $\dim N(\mathbf{A} - \rho(\mathbf{A})\mathbf{I}) \geq 2$.

$\Rightarrow \mathbf{A}_1$ 没有特征值 $\rho(\mathbf{A})$. 因此, $\rho(\mathbf{A})$ 的代数重数为 1.

四 正矩阵

例子： 1973年，Leontief(里昂惕夫)获得了诺贝尔经济学奖(Nobel prize in economics)，我们使用一个简单的例子说明Leontief输入-输出模型.假设有两个产业：木材和电力. 假设生产单位电需要0.4单位电和0.2单位木材.假设生产单位木材需要0.2单位电和0.1单位木材.如下图所示：

	电力	木材
电力	0.4	0.2
木材	0.2	0.1

$\Rightarrow \mathbf{A} = \begin{pmatrix} 0.4 & 0.2 \\ 0.2 & 0.1 \end{pmatrix}$ 称为消耗矩阵(Consumption matrix).

四 正矩阵

令 $\mathbf{P} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$ 是产量向量(Production vector), 即生产出 x_1 单位电和 x_2 单位木材. $\mathbf{AP} = \begin{pmatrix} 0.4x_1 + 0.2x_2 \\ 0.2x_1 + 0.1x_2 \end{pmatrix}$.

第一行表示生产出 x_1 单位电需要的成本, 第二行表示生产出 x_2 单位木材需要的成本.

\mathbf{AP} 是成本向量, $\mathbf{P} - \mathbf{AP} = (\mathbf{I} - \mathbf{A})\mathbf{P}$

设 $\mathbf{d} = \begin{pmatrix} d_1 \\ d_2 \end{pmatrix}$ 表示市场对电的需要为 d_1 单位, 对木材的需求为 d_2 单位.

若 $(\mathbf{I} - \mathbf{A})\mathbf{P} = \mathbf{d}$, 表示结余=需求(理想状态).

目标: 给定消耗矩阵 \mathbf{A} , 需求向量 \mathbf{d} , 求 \mathbf{P} , 使得 $(\mathbf{I} - \mathbf{A})\mathbf{P} = \mathbf{d}$.

若 $\mathbf{I} - \mathbf{A}$ 可逆, 则 $\mathbf{P} = (\mathbf{I} - \mathbf{A})^{-1}\mathbf{d}$. 还需要 $\mathbf{P} \geq \mathbf{0}$.

定义: 我们说 \mathbf{A} 是有效率的(Productive), 若 $\mathbf{I} - \mathbf{A}$ 可逆, 且 $\mathbf{I} - \mathbf{A}$ 的逆是正矩阵.

四 正矩阵

定理: 若 \mathbf{A} 是 n 阶正矩阵, 且 \mathbf{A} 的每行元素和小于 1, 则 \mathbf{A} 是有效率的.

证明: 考虑 $\mathbf{x} = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}_{n \times 1}$. 由已知, $\mathbf{Ax} < \mathbf{x}$, 则存在 $0 < \varepsilon < 1$, $\mathbf{Ax} < (1 - \varepsilon)\mathbf{x}$. 递归地, $\mathbf{A}^n \mathbf{x} < (1 - \varepsilon)^n \mathbf{x}$. $\lim_{n \rightarrow \infty} \mathbf{A}^n \mathbf{x} = \mathbf{0} \Rightarrow \lim_{n \rightarrow \infty} \mathbf{A}^n = \mathbf{0}$.

另一方面, \mathbf{A} 是正矩阵, 存在 $\alpha > 0$, $\mathbf{A}\alpha = \rho(\mathbf{A})\alpha$, $\mathbf{A}^n \alpha = \rho(\mathbf{A})^n \alpha$, 因为 $\lim_{n \rightarrow \infty} \mathbf{A}^n = \mathbf{0}$, 因此 $0 < \rho(\mathbf{A}) < 1$. 则 $\mathbf{I} - \mathbf{A}$ 的特征值均不等于 0, 故 $\mathbf{I} - \mathbf{A}$ 可逆, 且

$$(\mathbf{I} - \mathbf{A})^{-1} = \mathbf{I} + \mathbf{A} + \mathbf{A}^2 + \dots$$

上式右边除第一项外每项均为正矩阵, 因此 $(\mathbf{I} - \mathbf{A})^{-1}$ 是正矩阵.

我们的例子满足定理条件.