

第十二讲 范数理论及其应用

一、向量范数

1. 向量范数定义： 设 V 为数域 K 上的向量空间，若对于 V 的任一向量 x ，对应一个实值函数 $\|x\|$ ，并满足以下三个条件：

(1) 非负性 $\|x\| \geq 0$ ，等号当且仅当 $x=0$ 时成立；

(2) 齐次性 $\|\alpha x\| = |\alpha| \|x\|, \alpha \in K, x \in V$ ；

(3) 三角不等式 $\|x+y\| \leq \|x\| + \|y\|, x, y \in V$ 。

则称 $\|x\|$ 为 V 中向量 x 的范数，简称为向量范数。

例 1. $x \in C^n$ ，它可表示成 $x = [\xi_1 \ \xi_2 \ \cdots \ \xi_n]^T$ ， $\xi_i \in C$ ，

$\|x\|_2 = \left(\sum_{i=1}^n |\xi_i|^2 \right)^{1/2}$ 就是一种范数

证明:

(i) 非负性 $\|\mathbf{x}\|_2 = \left(\sum_{i=1}^n |\xi_i|^2 \right)^{1/2} \geq 0$, 当且仅当 $\xi_i = 0 (i=1, 2, \dots, n)$ 时, 即

$\mathbf{x} = \mathbf{0}$ 时, $\|\mathbf{x}\|_2 = 0$

(ii) 齐次性 $\|\alpha \mathbf{x}\|_2 = \left(\sum_{i=1}^n |\alpha \xi_i|^2 \right)^{1/2} = |\alpha| \left(\sum_{i=1}^n |\xi_i|^2 \right)^{1/2} = |\alpha| \|\mathbf{x}\|_2$

(iii) $\mathbf{y} = [\eta_1 \quad \eta_2 \quad \cdots \quad \eta_n]^T$, $\eta_i \in \mathbb{C}$

$$\mathbf{x} + \mathbf{y} = [\xi_1 + \eta_1 \quad \xi_2 + \eta_2 \quad \cdots \quad \xi_n + \eta_n]^T, \quad \|\mathbf{x} + \mathbf{y}\|_2^2 = \sum_{i=1}^n |\xi_i + \eta_i|^2$$

$$|\xi_i + \eta_i|^2 = |\xi_i|^2 + |\eta_i|^2 + 2\operatorname{Re}(\overline{\xi_i} \eta_i) \leq |\xi_i|^2 + |\eta_i|^2 + 2|\xi_i||\eta_i|$$

$$\|\mathbf{x} + \mathbf{y}\|_2^2 \leq \|\mathbf{x}\|_2^2 + \|\mathbf{y}\|_2^2 + 2 \sum_{i=1}^n |\xi_i||\eta_i|$$

$$(\|\mathbf{x}\|_2 + \|\mathbf{y}\|_2)^2 = \|\mathbf{x}\|_2^2 + \|\mathbf{y}\|_2^2 + 2\|\mathbf{x}\|_2 \|\mathbf{y}\|_2$$

根据 Hölder 不等式:

$$\sum_{i=1}^n a_i b_i \leq \left(\sum_{i=1}^n a_i^p \right)^{1/p} \left(\sum_{i=1}^n b_i^q \right)^{1/q}, \quad p, q > 1, \frac{1}{p} + \frac{1}{q} = 1, a_i, b_i > 0$$

$$\|x\|_2 \|y\|_2 = \left(\sum_{i=1}^n |\xi_i|^2 \right)^{1/2} \left(\sum_{i=1}^n |\eta_i|^2 \right)^{1/2} \geq \sum_{i=1}^n |\xi_i| |\eta_i|$$

$$\therefore \|x + y\|_2 \leq \|x\|_2 + \|y\|_2 \quad [\text{证毕}]$$

2. p-范数 (l_p 范数)

$$\|x\|_p = \left(\sum_{i=1}^n |\xi_i|^p \right)^{1/p} \quad (p \geq 1)$$

- 1-范数: $\|x\|_1 = \sum_{i=1}^n |\xi_i|$

- 2-范数: $\|x\|_2 = \left(\sum_{i=1}^n |\xi_i|^2 \right)^{1/2}$

- ∞ -范数 (chebyshev 范数): $\|x\|_\infty = \max |\xi_i| = \lim_{p \rightarrow \infty} \|x\|_p$

证明： $\|\mathbf{x}\|_p$ 显然满足非负性和齐次性

$$\mathbf{y} = [\eta_1 \quad \eta_2 \quad \cdots \quad \eta_n]^T$$

$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^n |\xi_i|^p \right)^{1/p}, \quad \|\mathbf{y}\|_p = \left(\sum_{i=1}^n |\eta_i|^p \right)^{1/p}, \quad \|\mathbf{x} + \mathbf{y}\|_p = \left(\sum_{i=1}^n |\xi_i + \eta_i|^p \right)^{1/p}$$

$$\left(\|\mathbf{x} + \mathbf{y}\|_p \right)^p = \sum_{i=1}^n |\xi_i + \eta_i|^p = \sum_{i=1}^n |\xi_i + \eta_i|^{p-1} |\xi_i + \eta_i|$$

$$\leq \sum_{i=1}^n |\xi_i + \eta_i|^{p-1} |\xi_i| + \sum_{i=1}^n |\xi_i + \eta_i|^{p-1} |\eta_i|$$

$$\leq \left(\sum_{i=1}^n |\xi_i|^p \right)^{1/p} \cdot \left(\sum_{i=1}^n |\xi_i + \eta_i|^{(p-1) \cdot \frac{p}{p-1}} \right)^{1-\frac{1}{p}} + \left(\sum_{i=1}^n |\eta_i|^p \right)^{1/p} \cdot \left(\sum_{i=1}^n |\xi_i + \eta_i|^{(p-1) \cdot \frac{p}{p-1}} \right)^{1-\frac{1}{p}}$$

$$= \left[\left(\sum_{i=1}^n |\xi_i|^p \right)^{1/p} + \left(\sum_{i=1}^n |\eta_i|^p \right)^{1/p} \right] \cdot \left(\sum_{i=1}^n |\xi_i + \eta_i|^p \right)^{1-\frac{1}{p}}$$

$$\therefore \left(\sum_{i=1}^n |\xi_i + \eta_i|^p \right)^{1/p} \leq \left(\sum_{i=1}^n |\xi_i|^p \right)^{1/p} + \left(\sum_{i=1}^n |\eta_i|^p \right)^{1/p}, \quad \text{即 } \|\mathbf{x} + \mathbf{y}\|_p \leq \|\mathbf{x}\|_p + \|\mathbf{y}\|_p \quad [\text{证毕}]$$

∞ -范数:

$$\text{设 } \max_i |\xi_i| = |\xi_{i0}|$$

$$\|x\|_p = \left(\sum_{i=1}^n |\xi_{i0}|^p \cdot \frac{|\xi_i|^p}{|\xi_{i0}|^p} \right)^{\frac{1}{p}} = |\xi_{i0}| \cdot \left(\sum_{i=1}^n \frac{|\xi_i|^p}{|\xi_{i0}|^p} \right)^{\frac{1}{p}}$$

$$\because |\xi_{i0}|^p \leq \sum_{i=1}^n |\xi_i|^p \leq n |\xi_{i0}|^p \quad \therefore 1 \leq \left(\sum_{i=1}^n \frac{|\xi_i|^p}{|\xi_{i0}|^p} \right)^{\frac{1}{p}} \leq n^{\frac{1}{p}}$$

$$\text{又} \because \lim_{p \rightarrow \infty} n^{\frac{1}{p}} = 1 \quad \therefore \lim_{p \rightarrow \infty} \|x\|_p = |\xi_{i0}| = \|x\|_\infty$$

3. 向量范数的等价性

定理: 设 $\|\cdot\|_\alpha$ 、 $\|\cdot\|_\beta$ 为 C^n 的两种向量范数, 则必定存在正数 m 、 M , 使得 $m\|x\|_\alpha \leq \|x\|_\beta \leq M\|x\|_\alpha$, (m 、 M 与 x 无关), 它被称为向量范数的等价性。

二、矩阵范数

1. 矩阵范数定义： 设 $k^{m \times n}$ ($k = \mathbb{C}$ 或 \mathbb{R}) 表示数域 k 上全体 $m \times n$ 阶矩阵的集合。若对于 $k^{m \times n}$ 中任一矩阵 A ，均对应一个实值函数，并满足以下四个条件：

(1) 非负性： $\|A\| \geq 0$ ， 等号当且仅当 $A=0$ 时成立；

(2) 齐次性： $\|\alpha A\| = |\alpha| \|A\|, \alpha \in k$ ；

(3) 三角不等式： $\|A + B\| \leq \|A\| + \|B\|, A, B \in k^{m \times n}$ ，则称 $\|A\|$ 为广义矩阵范数；

(4) 相容性： $\|AB\| \leq \|A\| \|B\|$ ，则称 $\|A\|$ 为矩阵范数。

2. 矩阵范数和向量范数

定义： 对于 $C^{m \times n}$ 上的矩阵范数 $\|\cdot\|_M$ 和 C^m 与 C^n 上的同类向量范数 $\|\cdot\|_V$ ，若

$$\|Ax\|_V \leq \|A\|_M \|x\|_V, \quad \forall A \in C^{m \times n}, \forall x \in C^n$$

则称矩阵范数 $\|\cdot\|_M$ 和向量范数 $\|\cdot\|_V$ 是相容的。

例：已知 $\mathbf{A} = (a_{ij}) \in C^{n \times n}$ ，试证明以下两个函数都是矩阵范数：

$$\|\mathbf{A}\|_{m_1} = \sum_{i,j=1}^n |a_{ij}| \quad \|\mathbf{A}\|_{m_\infty} = n \cdot \max_{i,j} |a_{ij}|$$

证明：对于函数 $\|\mathbf{A}\|_{m_1}$ ，其非负性和齐次性显然。下面证明三角不等式和相容性。

$$\begin{aligned} \|\mathbf{A} + \mathbf{B}\|_{m_1} &= \sum_{i,j=1}^n |a_{ij} + b_{ij}| \leq \sum_{i,j=1}^n (|a_{ij}| + |b_{ij}|) \\ &= \sum_{i,j=1}^n |a_{ij}| + \sum_{i,j=1}^n |b_{ij}| = \|\mathbf{A}\|_{m_1} + \|\mathbf{B}\|_{m_1} \end{aligned}$$

$$\begin{aligned} \|\mathbf{AB}\|_{m_1} &= \sum_{i,j=1}^n |a_{i1}b_{1j} + a_{i2}b_{2j} + \cdots + a_{in}b_{nj}| \leq \sum_{i,j=1}^n (|a_{i1}| |b_{1j}| + |a_{i2}| |b_{2j}| + \cdots + |a_{in}| |b_{nj}|) \\ &\leq \sum_{i=1}^n (|a_{i1}| + |a_{i2}| + \cdots + |a_{in}|) \times \sum_{j=1}^n (|b_{1j}| + |b_{2j}| + \cdots + |b_{nj}|) \\ &= \sum_{i,j=1}^n |a_{ij}| \cdot \sum_{i,j=1}^n |b_{ij}| = \|\mathbf{A}\|_{m_1} \cdot \|\mathbf{B}\|_{m_1} \end{aligned}$$

证毕

3. 常用的矩阵范数

(1) Frobenius 范数 (F-范数) 和导出性范数

$$\text{F-范数: } \|A\|_F = \left(\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2 \right)^{1/2} = (\text{tr}(A^H A))^{1/2}$$

(2) 导出性范数 (从属范数): 设 $\|x\|$ 为数域 K 上 n 维向量空间 K^n ($K=R$ 或 C) 的一种向量范数。可定义矩阵范数为:

$$\|A\| = \max_{\|x\|=1} \|Ax\| = \max_{x \neq 0} \left(\frac{\|Ax\|}{\|x\|} \right)$$

从属于向量范数 $\|x\|_1, \|x\|_2, \|x\|_\infty$ 的矩阵范数依次是:

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}| \quad \text{列 (和) 范数}$$

$$\|A\|_2 = \max_{1 \leq i \leq n} \sqrt{\lambda_i(A^H A)} \quad \text{谱范数}$$

$$\|A\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}| \quad \text{行 (和) 范数}$$

三、范数的应用

逼近和误差估计是矩阵范数应用的主要领域。

定义：设矩阵 A 可逆，称

$$\text{cond}(A) = \|A\| \|A^{-1}\|$$

为 A 的条件数。

由相容性可知： $\|A\| \|A^{-1}\| \geq \|AA^{-1}\| = \|I\|$

$$\|x\| = \|Ix\| \leq \|I\| \|x\| \Rightarrow \|I\| \geq 1$$

对于导出性范数 $\|I\| = 1$

$$\therefore \text{cond}(A) \geq 1$$

条件数反映了误差放大的程度，条件数越大，矩阵越病态。

1. 矩阵的摄动

定理 1: 设 $A \in C^{n \times n}$, 且对某种矩阵范数有 $\|A\| < 1$, 则矩阵 $I - A$ 非奇异, 且

$$\|(I - A)^{-1}\| \leq \frac{\|I\|}{1 - \|A\|}$$

证明: 设矩阵范数 $\|A\|$ 与向量范数 $\|x\|_V$ 相容, 假设 $I - A$ 为奇异矩阵, 则齐次方程 $(I - A)x = 0$ 有非零解 x_0 , 即有

$$(I - A)x_0 = 0, \quad x_0 \neq 0$$

则: $\|x_0\|_V = \|Ax_0\|_V \leq \|A\| \cdot \|x_0\|_V$

与 $\|A\| < 1$ 相矛盾, 故 $I - A$ 非奇异。又 $(I - A)(I - A)^{-1} = I$

所以, $(I - A)^{-1} = I + A(I - A)^{-1}$

$$\|(I - A)^{-1}\| \leq \|I\| + \|A\| \cdot \|(I - A)^{-1}\| \quad \text{即} \quad \|(I - A)^{-1}\| \leq \frac{\|I\|}{1 - \|A\|}$$

定理 2: 设 $A \in C^{n \times n}$, 且对某种矩阵范数有 $\|A\| < 1$, 则

$$\|I - (I - A)^{-1}\| \leq \frac{\|A\|}{1 - \|A\|}$$

证明: 因为 $\|A\| < 1$, 所以 $(I - A)^{-1}$ 存在。又

$$(I - A) - I = -A$$

可得
$$I - (I - A)^{-1} = -A(I - A)^{-1}$$

取范数
$$\|I - (I - A)^{-1}\| \leq \|A\| \cdot \|(I - A)^{-1}\|$$

即
$$\|I - (I - A)^{-1}\| \leq \frac{\|A\|}{1 - \|A\|}$$

定理 3: 设 A 可逆, δA 为摄动矩阵, 且 $\|A^{-1}\delta A\| < 1$, 则

(1) $A + \delta A$ 为可逆矩阵;

(2) $(A + \delta A)^{-1} = (I - F)A^{-1}$, 其中, $\|F\| \leq \frac{\|A^{-1}\delta A\|}{1 - \|A^{-1}\delta A\|}$;

(3) $\frac{\|A^{-1} - (A + \delta A)^{-1}\|}{\|A^{-1}\|} \leq \frac{\|A^{-1}\delta A\|}{1 - \|A^{-1}\delta A\|}$

推论: 若 $\|A^{-1}\| \cdot \|\delta A\| < 1$, 则

$$\|F\| \leq \frac{\text{cond}(A) \frac{\|\delta A\|}{\|A\|}}{1 - \text{cond}(A) \frac{\|\delta A\|}{\|A\|}}, \quad \frac{\|A^{-1} - (A + \delta A)^{-1}\|}{\|A^{-1}\|} \leq \frac{\text{cond}(A) \frac{\|\delta A\|}{\|A\|}}{1 - \text{cond}(A) \frac{\|\delta A\|}{\|A\|}}$$

例： $A = \begin{bmatrix} 2 & 6 \\ 2 & 6.00001 \end{bmatrix}, \quad \delta A = \begin{bmatrix} 0 & 0 \\ 0 & -0.00002 \end{bmatrix}$

计算得： $A^{-1} = \begin{bmatrix} 300000.5 & -300000 \\ -100000 & 100000 \end{bmatrix}$

$$(A + \delta A)^{-1} = \begin{bmatrix} -299999.5 & -300000 \\ 100000 & -100000 \end{bmatrix}$$

其条件数 $cond(A) = \|A\|_2 \cdot \|A^{-1}\|_2 \approx 1105$

2. 线性方程组的摄动

对于方程 $\mathbf{Ax} = \mathbf{b} \rightarrow \mathbf{x} = \mathbf{A}^{-1}\mathbf{b}$

(1) \mathbf{b} 存在误差 $\Delta\mathbf{b}$ ，求出的 \mathbf{x} 存在误差 $\Delta\mathbf{x}$ ， $\Delta\mathbf{x} = \mathbf{A}^{-1}\Delta\mathbf{b}$

$$\|\Delta\mathbf{x}\| \leq \|\mathbf{A}^{-1}\| \|\Delta\mathbf{b}\|, \text{考察相对误差, 求 } \frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|}$$

$$\|\mathbf{b}\| \leq \|\mathbf{A}\| \|\mathbf{x}\| \rightarrow \|\mathbf{x}\| \geq \frac{\|\mathbf{b}\|}{\|\mathbf{A}\|} \quad \therefore \quad \frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} \leq \|\mathbf{A}\| \|\mathbf{A}^{-1}\| \frac{\|\Delta\mathbf{b}\|}{\|\mathbf{b}\|}$$

$$\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} / \frac{\|\Delta\mathbf{b}\|}{\|\mathbf{b}\|} \leq \|\mathbf{A}\| \|\mathbf{A}^{-1}\| = \mathbf{cond}(\mathbf{A})$$

(2) \mathbf{A} 存在误差 $\Delta\mathbf{A}$ ，求出的解 \mathbf{x} 存在误差 $\Delta\mathbf{x}$

$$\mathbf{Ax} = \mathbf{b} \quad (\mathbf{A} + \Delta\mathbf{A})(\mathbf{x} + \Delta\mathbf{x}) = \mathbf{b} \rightarrow \mathbf{A}\Delta\mathbf{x} = -\Delta\mathbf{A}\mathbf{x} - \Delta\mathbf{A}\Delta\mathbf{x}$$

忽略高阶小量得: $\|\Delta\mathbf{x}\| \leq \|\mathbf{A}^{-1}\| \|\Delta\mathbf{A}\| \|\mathbf{x}\|$

$$\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} \leq \|\mathbf{A}^{-1}\| \|\mathbf{A}\| \frac{\|\Delta\mathbf{A}\|}{\|\mathbf{A}\|}$$

$$\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} / \frac{\|\Delta\mathbf{A}\|}{\|\mathbf{A}\|} \leq \|\mathbf{A}^{-1}\| \|\mathbf{A}\| = \mathbf{cond}(\mathbf{A})$$

常用条件数用 $\|\mathbf{A}\|_2$ 来考虑:

$$\|\mathbf{A}\|_2 = \sqrt{\lambda_{\max}(\mathbf{A}^H \mathbf{A})}$$

$$\|\mathbf{A}^{-1}\|_2 = \sqrt{\lambda_{\min}^{-1}(\mathbf{A}^H \mathbf{A})}$$

$$\text{cond}(\mathbf{A}) = \sqrt{\frac{\lambda_{\max}(\mathbf{A}^H \mathbf{A})}{\lambda_{\min}(\mathbf{A}^H \mathbf{A})}}$$

作业: **P275 1、2**