

第十七讲 广义特征值与极小极大原理

一、广义特征值问题

1.定义：设 A 、 B 为 n 阶方阵，若存在数 λ ，使得方程

$$Ax = \lambda Bx$$

存在非零解，则称 λ 为 A 相对于 B 的广义特征值， x 为 A 相对于 B 的属于广义特征值 λ 的特征向量。

■ 广义特征值的求解

$$(A - \lambda B)x = 0 \quad \text{或者} \quad (\lambda B - A)x = 0$$

$$\rightarrow \text{特征方程} \quad \det(A - \lambda B) = 0$$

求得 λ 后代回原方程 $Ax = \lambda Bx$ 可求出 x

考虑A、B厄米且为正定矩阵的情况

2. 广义特征值问题的等价形式

- B 正定， B^{-1} 存在 $\rightarrow B^{-1}Ax = \lambda x$ ，广义特征值问题化为了标准特征值问题，但一般来说， $B^{-1}A$ 一般不再是厄米矩阵。

- B 厄米，存在 Cholesky 分解， $B = GG^H$ ，G 为下三角矩阵

$$Ax = \lambda GG^H x$$

令 $G^H x = y$ ，则

$$G^{-1}A(G^H)^{-1}y = \lambda y$$

也成为标准特征值问题。

$G^{-1}A(G^H)^{-1}$ 为厄米矩阵，其广义特征值为实数，且一定存在一组正交归一的特征向量，即存在 y_1, y_2, \dots, y_n 满足：

$$\mathbf{G}^{-1}\mathbf{A}(\mathbf{G}^H)^{-1}\mathbf{y}_i = \lambda\mathbf{y}_i \quad \mathbf{y}_i^H\mathbf{y}_j = \delta_{ij} = \begin{cases} 1 & i=j \\ 0 & i \neq j \end{cases}$$

还原为

$$\mathbf{x}_i = (\mathbf{G}^H)^{-1}\mathbf{y}_i \quad (i=1,2,\dots,n), \text{ 则}$$

$$\mathbf{y}_i^H\mathbf{y}_j = (\mathbf{x}_i^H\mathbf{G})(\mathbf{G}^H\mathbf{x}_j) = \mathbf{x}_i^H\mathbf{B}\mathbf{x}_j = \delta_{ij} = \begin{cases} 1 & i=j \\ 0 & i \neq j \end{cases}$$

这一组 x_i 称为按 \mathbf{B} 标准正交化向量系。

按 \mathbf{B} 标准正交化向量系 x_1, x_2, \dots, x_n 具有如下性质：

- (1) $x_i \neq 0$; (2) x_1, x_2, \dots, x_n 线性无关。

二、瑞利商和广义特征值的极小极大原理

1.瑞利商的定义： \mathbf{A} 、 \mathbf{B} 为 n 阶厄米矩阵，且 \mathbf{B} 正定，称

$\mathbf{R}(\mathbf{x}) = \frac{\mathbf{x}^H \mathbf{A} \mathbf{x}}{\mathbf{x}^H \mathbf{B} \mathbf{x}} (\mathbf{x} \neq \mathbf{0})$ 为 \mathbf{A} 相对于 \mathbf{B} 的瑞利商。

设 $\lambda_1, \lambda_2, \dots, \lambda_n$ 是 \mathbf{A} 相对于 \mathbf{B} 的广义特征值，且 $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$ ， $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 为对应的按 \mathbf{B} 标准正交化向量系，则 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 线性无关。

$\forall \mathbf{x} \in C^n$ 存在 $a_1, a_2, \dots, a_n \in C$ ，使得 $\mathbf{x} = \sum_{i=1}^n \mathbf{a}_i \mathbf{x}_i$ ，则

$$\mathbf{x}^H \mathbf{B} \mathbf{x} = \left(\sum_{i=1}^n \mathbf{a}_i \mathbf{x}_i \right)^H \mathbf{B} \left(\sum_{j=1}^n \mathbf{a}_j \mathbf{x}_j \right) = \sum_{i,j=1}^n \bar{\mathbf{a}}_i \mathbf{a}_j \mathbf{x}_i^H \mathbf{B} \mathbf{x}_j = \sum_{i=1}^n |\mathbf{a}_i|^2$$

$$\mathbf{x}^H \mathbf{A} \mathbf{x} = \sum_{i,j=1}^n \bar{\mathbf{a}}_i \mathbf{a}_j \mathbf{x}_i^H \mathbf{A} \mathbf{x}_j = \sum_{i,j=1}^n \bar{\mathbf{a}}_i \mathbf{a}_j \mathbf{x}_i^H \lambda_i \mathbf{B} \mathbf{x}_j = \sum_{i=1}^n \lambda_i |\mathbf{a}_i|^2$$

$$\therefore R(\mathbf{x}) = \frac{\sum_{i=1}^n \lambda_i |\mathbf{a}_i|^2}{\sum_{i=1}^n |\mathbf{a}_i|^2}$$

2. $\min_{\mathbf{x} \neq 0} R(\mathbf{x}) = \lambda_1 \quad \max_{\mathbf{x} \neq 0} R(\mathbf{x}) = \lambda_n$

证明: $R(\mathbf{x}) = \frac{\mathbf{x}^H \mathbf{A} \mathbf{x}}{\mathbf{x}^H \mathbf{B} \mathbf{x}} = \frac{(\mathbf{kx})^H \mathbf{A} (\mathbf{kx})}{(\mathbf{kx})^H \mathbf{B} (\mathbf{kx})} \quad \mathbf{k} \text{ 为非零常数}$

可取 $\mathbf{k} = \frac{1}{\|\mathbf{x}\|}$, $\|\mathbf{kx}\| = 1 \quad \therefore R(\mathbf{x}) = \left. \frac{\mathbf{x}^H \mathbf{A} \mathbf{x}}{\mathbf{x}^H \mathbf{B} \mathbf{x}} \right|_{\|\mathbf{x}\|=1}$

当 $\mathbf{x} = \mathbf{x}_1$ 或 $\mathbf{a}_i = 0 (i = 2, 3, \dots, n)$ 时, $R(\mathbf{x}) = \lambda_1$

$$\lambda_i \geq \lambda_1 \quad R(\mathbf{x}) \geq \lambda_1 \frac{\sum_{i=1}^n |\mathbf{a}_i|^2}{\sum_{i=1}^n |\mathbf{a}_i|^2} = \lambda_1 \quad \therefore \min_{\mathbf{x} \neq 0} R(\mathbf{x}) = \lambda_1$$

另一方面, $\lambda_i \leq \lambda_n$

$$\mathbf{R}(\mathbf{x}) \leq \lambda_n \frac{\sum_{i=1}^n |\mathbf{a}_i|^2}{\sum_{i=1}^n |\mathbf{a}_i|^2} = \lambda_n$$

$$\therefore \max_{\mathbf{x} \neq 0} \mathbf{R}(\mathbf{x}) = \lambda_n \quad [\text{证毕}]$$

当 $\mathbf{B}=\mathbf{I}$ 时, 化为标准特征值问题 $\mathbf{A}\mathbf{x} = \lambda\mathbf{x} \quad (\mathbf{A}^H = \mathbf{A})$

设 $\begin{cases} \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n \\ \mathbf{x}_i^H \mathbf{x}_j = \delta_{ij} \end{cases}$ 则 $\min_{(\mathbf{x} \neq 0)} \frac{\mathbf{x}^H \mathbf{A} \mathbf{x}}{\mathbf{x}^H \mathbf{x}} = \lambda_1 \quad \max_{(\mathbf{x} \neq 0)} \frac{\mathbf{x}^H \mathbf{A} \mathbf{x}}{\mathbf{x}^H \mathbf{x}} = \lambda_n$

进一步分析可得

$$\begin{array}{ll} \min_{\mathbf{x} \neq 0} \mathbf{R}(\mathbf{x}) \Big|_{\mathbf{a}_1=0} = \lambda_2 & \max_{\mathbf{x} \neq 0} \mathbf{R}(\mathbf{x}) \Big|_{\mathbf{a}_n=0} = \lambda_{n-1} \\ \vdots & \vdots \\ \min_{\mathbf{x} \neq 0} \mathbf{R}(\mathbf{x}) \Big|_{\mathbf{a}_1=\mathbf{a}_2=\dots=\mathbf{a}_k=0} = \lambda_{k+1} & \max_{\mathbf{x} \neq 0} \mathbf{R}(\mathbf{x}) \Big|_{\mathbf{a}_n=\mathbf{a}_{n-1}=\dots=\mathbf{a}_{n-k}=0} = \lambda_{n-k-1} \end{array}$$

3. 定理 1. 设 $L = \text{span}\{\mathbf{x}_r, \mathbf{x}_{r+1}, \dots, \mathbf{x}_s\}$ ($\lambda_r \leq \lambda_{r+1} \leq \dots \leq \lambda_s$), 则

$$\min_{\substack{\mathbf{x} \neq 0 \\ \mathbf{x} \in L}} \mathbf{R}(\mathbf{x}) = \lambda_r \quad \max_{\substack{\mathbf{x} \neq 0 \\ \mathbf{x} \in L}} \mathbf{R}(\mathbf{x}) = \lambda_s$$

$\mathbf{a}_1 = 0$ 和 $\mathbf{a}_n = 0$ 的情况均对应于 \mathbf{x} 在 $(n-1)$ 维的子空间内变动, \mathbf{x} 在 L 中变动是在一个 $(s-r+1)$ 维子空间中变化。

一般的, \mathbf{x} 在 C^n 的 $(n-1)$ 维子空间 V_{n-1} 中变动时,

$$\min_{\substack{\mathbf{x} \neq 0 \\ \mathbf{x} \in V_{n-1}}} \mathbf{R}(\mathbf{x}) \leq \lambda_2 \quad \max_{\substack{\mathbf{x} \neq 0 \\ \mathbf{x} \in V_{n-1}}} \mathbf{R}(\mathbf{x}) \geq \lambda_{n-1}$$

即对于不同的 V_{n-1} , $\mathbf{R}(\mathbf{x})$ 的最小值及最大值有可能不同, 其中各个最小值中最大者为 λ_2 , 各个最大值中的最小者为 λ_{n-1} :

$$\max_{V_{n-1} \in C^n} \left[\min_{\substack{\mathbf{x} \neq 0 \\ \mathbf{x} \in V_{n-1}}} \mathbf{R}(\mathbf{x}) \right] = \lambda_2 \quad \min_{V_{n-1} \in C^n} \left[\max_{\substack{\mathbf{x} \neq 0 \\ \mathbf{x} \in V_{n-1}}} \mathbf{R}(\mathbf{x}) \right] = \lambda_{n-1}$$

定理 2. 设 V_k 是 C^n 的一个 k 维子空间, 则

$$\max_{V_k \in C^n} \left[\min_{\substack{x \neq 0 \\ x \in V_k}} R(x) \right] = \lambda_{n-k+1} \quad \min_{V_k \in C^n} \left[\max_{\substack{x \neq 0 \\ x \in V_k}} R(x) \right] = \lambda_k$$

说明: (1) $B=I$ 时, 标准特征值问题同样存在上述关系。

(2) 矩阵奇异值问题:

$$[\sigma(A)]^2 = \lambda(A^H A) \quad (\text{非零})$$

$$R(x) = \frac{x^H (A^H A) x}{x^H x} = \frac{\|Ax\|_2^2}{\|x\|_2^2}$$

$$\sigma_{n-k+1} = \max_{V_k \in C^n} \left[\min_{\substack{x \neq 0 \\ x \in V_k}} \frac{\|Ax\|_2}{\|x\|_2} \right]$$

$$\sigma_k = \min_{V_k \in C^n} \left[\max_{\substack{x \neq 0 \\ x \in V_k}} \frac{\|Ax\|_2}{\|x\|_2} \right]$$