



§ 3 奇异值分解

3.1 引言

- 对角阵是我们最喜爱的一类矩阵.
- n 阶矩阵 A 相似于对角阵 $\Leftrightarrow A$ 存在 n 个线性无关的特征向量.
- 实对称矩阵正交相似于对角阵

3.1 引言

问题:如何“对角化” $m \times n$ 矩阵?

3.2 奇异值分解(Singular Value Decomposition)

设A是一个 $m \times n$ 矩阵, 则存在m阶正交矩阵U和n阶正交矩阵V, 满足

$$A = U \begin{pmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \\ & & & 0 \end{pmatrix}_{m \times n} V^T =: U \Sigma V^T,$$

其中 $r = \text{rank} A$. 习惯上, 设 $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$. 称 $\sigma_1, \cdots, \sigma_r$ 为奇异值(singular value). 称U和V的前r列向量为奇异向量(singular vector). 这个分解为奇异值分解, 简称**SVD**.

3.2 奇异值分解(Singular Value Decomposition)

令 $U = (\mathbf{u}_1 \cdots \mathbf{u}_r \mathbf{u}_{r+1} \cdots \mathbf{u}_m)$, $V = (\mathbf{v}_1 \cdots \mathbf{v}_r \mathbf{v}_{r+1} \cdots \mathbf{v}_n)$.

$$\begin{aligned} \text{SVD} \Rightarrow \quad & A\mathbf{v}_i = \sigma_i \mathbf{u}_i, & A\mathbf{v}_j = \mathbf{0} \quad (j = r+1, \cdots, n), \\ & (i = 1, \cdots, r) & \\ & A^T \mathbf{u}_i = \sigma_i \mathbf{v}_i, & A^T \mathbf{u}_k = \mathbf{0} \quad (k = r+1, \cdots, m). \end{aligned}$$

$$\Rightarrow A^T A \mathbf{v}_i = \sigma_i^2 \mathbf{v}_i, \quad A A^T \mathbf{u}_i = \sigma_i^2 \mathbf{u}_i \quad (1 \leq i \leq r).$$

3.2 奇异值分解(Singular Value Decomposition)

设 A 是秩为 r 的 $m \times n$ 实矩阵,则 AA^T 为 m 阶实对称矩阵, $A^T A$ 为 n 阶实对称矩阵.

(1) AA^T 与 $A^T A$ 的特征值为非负数.

证明: 设 $A^T A \mathbf{x} = \lambda \mathbf{x} (\mathbf{x} \neq \mathbf{0})$, 则 $\mathbf{x}^T A^T A \mathbf{x} = \lambda \mathbf{x}^T \mathbf{x}$, 即

$$\|A\mathbf{x}\|^2 = \lambda \|\mathbf{x}\|^2,$$

故 $\lambda \geq 0$. 同理 AA^T 的特征值也全是非负数.

3.2 奇异值分解(Singular Value Decomposition)

(2) AA^T 与 $A^T A$ 的非零特征值集合相同.

证明: 因为 $r(AA^T) = r(A^T A) = r(A) = r$, 故

$$\#\{A^T A \text{ 的非零特征值}\} = r = \#\{AA^T \text{ 的非零特征值}\}$$

设 λ 是 $A^T A$ 的非零特征值. 即 $\exists \mathbf{x}$, 使得 $A^T A \mathbf{x} = \lambda \mathbf{x}$.

则有 $AA^T A \mathbf{x} = \lambda A \mathbf{x}$. 故 λ 也是 AA^T 的非零特征值. 反之亦然.

因此, AA^T 与 $A^T A$ 具有相同的非零特征值.

3.2 奇异值分解(Singular Value Decomposition)

不妨设 AA^T 和 $A^T A$ 的这 r 个非零特征值为 $\sigma_1^2 \geq \cdots \geq \sigma_r^2 > 0$, 其中 $\sigma_i > 0$.

(3) 设 $\mathbf{v}_1, \cdots, \mathbf{v}_n \in \mathbb{R}^n$ 为 n 阶实对称方阵 $A^T A$ 的单位正交特征向量,

$$A^T A(\mathbf{v}_1 \cdots \mathbf{v}_n) = (\mathbf{v}_1 \cdots \mathbf{v}_n) \begin{pmatrix} \sigma_1^2 & & & \\ & \ddots & & \\ & & \sigma_r^2 & \\ & & & 0 \end{pmatrix}.$$

记 $V = (\mathbf{v}_1, \cdots, \mathbf{v}_n)$, 则 $V^T V = I_n$.

3.2 奇异值分解(Singular Value Decomposition)

注意到 $A^T A \mathbf{v}_i = \sigma_i^2 \mathbf{v}_i$, $(1 \leq i \leq r)$.

故 $\mathbf{v}_i^T A^T A \mathbf{v}_i = \sigma_i^2 \mathbf{v}_i^T \mathbf{v}_i$, 即 $\|A \mathbf{v}_i\|^2 = \sigma_i^2$.

令 $\mathbf{u}_i := \frac{A \mathbf{v}_i}{\sigma_i} \in \mathbb{R}^m (1 \leq i \leq r)$, 则 $AA^T \mathbf{u}_i = \sigma_i^2 \mathbf{u}_i$, 并且

$$\mathbf{u}_i^T \mathbf{u}_j = \frac{(A \mathbf{v}_i)^T}{\sigma_i} \frac{A \mathbf{v}_j}{\sigma_j} = \frac{\mathbf{v}_i^T (A^T A \mathbf{v}_j)}{\sigma_i \sigma_j} = \frac{\sigma_j^2 \mathbf{v}_i^T \mathbf{v}_j}{\sigma_i \sigma_j} = \frac{\sigma_j}{\sigma_i} \delta_{ij} = \delta_{ij}.$$

故 $\{\mathbf{u}_i \mid 1 \leq i \leq r\}$ 是 AA^T 的单位正交特征向量.

3.2 奇异值分解(Singular Value Decomposition)

又

$$\boxed{A\mathbf{v}_i = \sigma_i\mathbf{u}_i}, \quad \boxed{A^T\mathbf{u}_i = \sigma_i\mathbf{v}_i}, \quad 1 \leq i \leq r.$$

故

$\{\mathbf{u}_1, \cdots, \mathbf{u}_r\}$ 为 $C(A)$ 的一组单位正交基;

$\{\mathbf{v}_1, \cdots, \mathbf{v}_r\}$ 为 $C(A^T)$ 的一组单位正交基.

3.2 奇异值分解(Singular Value Decomposition)

$$A(\mathbf{v}_1 \cdots \mathbf{v}_r) = (\mathbf{u}_1 \cdots \mathbf{u}_r) \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{pmatrix}$$

记为 $A_{m \times n} V_{n \times r} = U_{m \times r} \Sigma_{r \times r}$.

回顾 $\mathbb{R}^n = C(A^T) \oplus N(A)$, $\mathbb{R}^m = C(A) \oplus N(A^T)$,
扩充 $\{\mathbf{v}_1, \cdots, \mathbf{v}_r\}$ 为 \mathbb{R}^n 的一组基 $\{\mathbf{v}_1, \cdots, \mathbf{v}_r, \mathbf{v}_{r+1}, \cdots, \mathbf{v}_n\}$,
扩充 $\{\mathbf{u}_1, \cdots, \mathbf{u}_r\}$ 为 \mathbb{R}^m 的一组基 $\{\mathbf{u}_1, \cdots, \mathbf{u}_r, \mathbf{u}_{r+1}, \cdots, \mathbf{u}_m\}$.

3.2 奇异值分解(Singular Value Decomposition)

$$\Rightarrow A(\mathbf{v}_1 \cdots \mathbf{v}_r \mathbf{v}_{r+1} \cdots \mathbf{v}_n) = (\mathbf{u}_1 \cdots \mathbf{u}_r \mathbf{u}_{r+1} \cdots \mathbf{u}_m) \begin{pmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \\ & & & 0 \end{pmatrix}_{m \times n}$$

即 $A_{m \times n} V_{n \times n} = U_{m \times m} \Sigma_{m \times n}$, 其中 $V^T V = I_n, U^T U = I_m$.

$$\Rightarrow \begin{aligned} A &= U \Sigma V^T, & (SVD) \\ A &= \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \cdots + \sigma_r \mathbf{u}_r \mathbf{v}_r^T. \end{aligned}$$

3.3 例题

例: 求矩阵 $A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & -1 \end{pmatrix}$ 的奇异值分解.

解: 因 $A^T A = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & -1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & -1 \end{pmatrix} = \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix},$

故 $A^T A$ 的特征多项式为

$$|\lambda I - A^T A| = \begin{vmatrix} \lambda - 2 & 1 \\ 1 & \lambda - 2 \end{vmatrix} = (\lambda - 1)(\lambda - 3).$$

3.3 例题

因此 $A^T A$ 的特征值为 $\sigma_1^2 = 3, \sigma_2^2 = 1$. 它们相应的单位特征向量分别为

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

AA^T 的三个特征值分别为 $\sigma_1^2 = 3, \sigma_2^2 = 1, 0$, 且属于它们的单位特征向量分别为

$$\mathbf{u}_1 = \frac{1}{\sigma_1} A \mathbf{v}_1 = \frac{1}{\sqrt{6}} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}, \quad \mathbf{u}_2 = \frac{1}{\sigma_2} A \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \\ 2 \end{pmatrix}, \quad \mathbf{u}_3 = \frac{1}{\sqrt{3}} \begin{pmatrix} 1 \\ -1 \\ -1 \end{pmatrix}.$$

3.3 例题

$$\text{令 } V = (\mathbf{v}_1 \ \mathbf{v}_2), \quad U = (\mathbf{u}_1 \ \mathbf{u}_2, \mathbf{u}_3), \quad \Sigma = \begin{pmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix},$$

$$\text{则 } A = U\Sigma V^T = \begin{pmatrix} \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ -\frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{3}} \\ \frac{2}{\sqrt{6}} & 0 & -\frac{1}{\sqrt{3}} \end{pmatrix} \begin{pmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}.$$

3.3 例题

例 (奇异值分解的几何意义):

设 $A = \begin{pmatrix} 3 & -4 \\ 5 & 0 \end{pmatrix}$, 则线性变换 $\mathbf{x} \mapsto A\mathbf{x}$ 把 \mathbb{R}^2 中的单位圆周

$S^1 = \{(x, y) \in \mathbb{R}^2 \mid x^2 + y^2 = 1\}$ 映成 \mathbb{R}^2 中的一个椭圆.

事实上, 由于 $A^T A = \begin{pmatrix} 34 & -12 \\ -12 & 16 \end{pmatrix}$ 的特征值为 $\sigma_1^2 = 40, \sigma_2^2 = 10$,

它们相应的单位特征向量分别为

3.3 例题

$$\mathbf{v}_1 = \frac{1}{\sqrt{5}} \begin{pmatrix} 2 \\ -1 \end{pmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 \\ 2 \end{pmatrix}.$$

AA^T 的特征值也为 $\sigma_1^2 = 40, \sigma_2^2 = 10$, 且属于它们的单位特征向量分别为

$$\mathbf{u}_1 = \frac{1}{\sigma_1} A \mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \mathbf{u}_2 = \frac{1}{\sigma_2} A \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \end{pmatrix}.$$

$$\text{令 } V = (\mathbf{v}_1 \ \mathbf{v}_2), \quad U = (\mathbf{u}_1 \ \mathbf{u}_2), \quad \Sigma = \begin{pmatrix} \sigma_1 & \\ & \sigma_2 \end{pmatrix} = \begin{pmatrix} 2\sqrt{10} & \\ & \sqrt{10} \end{pmatrix},$$


3.3 例题

则A的奇异值分解为

$$A = U\Sigma V^T = \begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} \begin{pmatrix} 2\sqrt{10} & \\ & \sqrt{10} \end{pmatrix} \begin{pmatrix} \frac{2}{\sqrt{5}} & -\frac{1}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} & \frac{2}{\sqrt{5}} \end{pmatrix}.$$

3.3 例题

矩阵A在单位圆周 S^1 上的作用可被分解成三步:



3.3 例题

注: 一般地, 设秩为 r 的 $m \times n$ 矩阵 A 有SVD: $A_{m \times n} = U\Sigma V^T$, 则从 \mathbb{R}^n 到 \mathbb{R}^m 的线性变换 $\mathbf{x} \mapsto A\mathbf{x}$ 可看成是以下三步的复合:

① \mathbb{R}^n 中的旋转 $\mathbf{x} \mapsto V^T \mathbf{x}$,

② \mathbb{R}^n 中的向量 $V^T \mathbf{x}$ 的前 r 个分量做伸缩, 其余分量变为0:

$$V^T \mathbf{x} \mapsto \Sigma V^T \mathbf{x},$$

③ 再在 \mathbb{R}^m 中做旋转 $\Sigma V^T \mathbf{x} \mapsto U\Sigma V^T \mathbf{x}$.

3.4 奇异值分解的应用

(1) SVD与矩阵的四个基本子空间:

设 $A = U\Sigma V^T$ 是 $m \times n$ 实矩阵 A 的奇异值分解, $r = r(A)$, 则

- ◆ 正交矩阵 U 的前 r 列是 $C(A)$ 的一组标准正交基;
- ◆ 正交矩阵 U 的后 $m-r$ 列是 $N(A^T)$ 的一组标准正交基;
- ◆ 正交矩阵 V 的前 r 列是 $C(A^T)$ 的一组标准正交基;
- ◆ 正交矩阵 V 的后 $n-r$ 列是 $N(A)$ 的一组标准正交基.

3.4 奇异值分解的应用

(2) SVD与图像压缩:

设秩 r 的 $m \times n$ 矩阵 A 的奇异值分解为

$$A = U\Sigma V^T = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \cdots + \sigma_r \mathbf{u}_r \mathbf{v}_r^T,$$

其中 $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$.

令 $A_k = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \cdots + \sigma_k \mathbf{u}_k \mathbf{v}_k^T$ ($1 \leq k < r$),
称为 A 的 k 阶逼近. 特别地, $k = 1$ 时, A_1 是 1 阶逼近.

3.4 奇异值分解的应用

例：一幅规格是 $m \times n$ 像素的照片可用一个 $m \times n$ 矩阵来储存。利用矩阵的奇异值分解，只需存储矩阵的奇异值 σ_i ，奇异向量 $\mathbf{u}_i, \mathbf{v}_i$ 的分量，总计 $r \cdot (m + n + 1)$ 个数据，而不是原始的 $m \cdot n$ 个数据。通常 $r \ll m, r \ll n$ ，则 $r \cdot (m + n + 1) \ll m \cdot n$ 。

比值 $\frac{m \cdot n}{r \cdot (m + n + 1)}$ 称为图像的压缩比 (其倒数称为数据压缩率)。

若 $\sigma_1, \dots, \sigma_k$ 远大于 $\sigma_{k+1}, \dots, \sigma_r$ ，则 $A_k \approx A$ ，图像不失真且压缩了存储量。

3.4 奇异值分解的应用

(3) SVD与特征值:

命题: 设 $|\lambda|_{\max}$ 是矩阵A的特征值的模长的最大值, 则

$$\sigma_1 \geq |\lambda|_{\max}, \sigma_1 \geq |a_{ij}|, \quad \forall i, j.$$

证明: 设A有奇异值分解 $A = U\Sigma V^T$, 则对任意向量 \mathbf{x} , 有

$$\|A\mathbf{x}\| = \|U\Sigma V^T \mathbf{x}\| = \|\Sigma V^T \mathbf{x}\| \leq \sigma_1 \|V^T \mathbf{x}\| = \sigma_1 \|\mathbf{x}\|.$$

3.4 奇异值分解的应用

若 $A\mathbf{x} = \lambda\mathbf{x}$, 则 $\|A\mathbf{x}\| = |\lambda| \cdot \|\mathbf{x}\|$, 故 $\sigma_1 \geq |\lambda|$, 特别有 $\sigma_1 \geq |\lambda|_{\max}$.

又若取 $\mathbf{x} = (1, 0, \dots, 0)$, 则 $A\mathbf{x}$ 表示 A 的第一列向量, 且 $\|A\mathbf{x}\| \leq \sigma_1 \|\mathbf{x}\| = \sigma_1$, 而

$$|a_{i1}| \leq \sqrt{a_{11}^2 + \dots + a_{n1}^2} \leq \sigma_1.$$

同理, $|a_{ij}| \leq \sigma_1$.

3.4 奇异值分解的应用

命题 (奇异值与奇异矩阵): 矩阵 A 列满秩 $\Leftrightarrow A$ 的奇异值均非零.
特别地, 方阵 A 非奇异 $\Leftrightarrow A$ 的奇异值均非零.

注: 矩阵的奇异值较之其特征值的一个优点是非零奇异值的个数恰好是矩阵的秩, 而矩阵的非零特征值的个数一般比其秩小 (如幂零矩阵无非零特征值), 故常以此来计算矩阵的秩.